

Fiche de révision V2 complète

Fusion des deux fiches générées + extraction enrichie des 3 chapitres + inspiration TD n°1

VERSION EXAMEN

Objectif de cette version

- Réviser rapidement les notions qui peuvent tomber dans le devoir.
- Combiner la fiche détaillée et la fiche style TD.
- Ajouter les métriques de classification : Accuracy, Precision, Recall, Specificity, F1-score, ROC, AUC.
- Garder un design simple : encadrés, tableaux, formules et questions probables.


1. Chapitre 1 — Introduction IA & Machine Learning

BASE

À garder — historique ignoré

- IA : domaine qui crée des systèmes capables d'accomplir des tâches nécessitant normalement l'intelligence humaine : reconnaissance, décision, apprentissage, résolution de problèmes.
- Machine Learning : sous-discipline de l'IA où un système apprend à partir des données pour prédire, classifier ou prendre une décision.
- Deep Learning : famille de méthodes ML basées sur des réseaux de neurones profonds, utile pour images, texte, voix et grandes quantités de données.

4. Relation entre IA, Machine Learning et Deep Learning



19

Figure — Relation IA / ML / Deep Learning (Chapitre_1_Introduction.pdf, p. 19)

IA discriminative

- Apprend directement la relation $X \rightarrow Y$.
- Objectif : classifier ou prédire.
- Exemples : détection spam, chat/chien, prédiction de prix.


IA générative

- Apprend la distribution des données.
- Objectif : générer des données réalistes.
- Exemples : génération texte, image, musique.

Types d'apprentissage

5. Type d'apprentissage

Les principaux types d'apprentissage incluent :



27

Figure — Types d'apprentissage (Chapitre_1_Introduction.pdf, p. 27)

Type	Données	But	Exemple TD/examen
------	---------	-----	-------------------

Supervisé	X + label Y	Apprendre une fonction $X \rightarrow Y$	Classification, régression
Non supervisé	Sans labels	Trouver une structure cachée	Clustering / K-means
Semi-supervisé	Peu de labels + beaucoup sans labels	Exploiter données non labellisées	Images avec peu d'annotations
Renforcement	Agent + environnement + récompense/pénalité	Maximiser récompense cumulée	Robot/navigation, jeu

VOCAB


Dataset — vocabulaire obligatoire

- Sample / échantillon : une observation ou une ligne.
- Feature / caractéristique : variable descriptive d'un sample.
- Label / target : sortie connue à prédire en supervisé.
- Training data : données utilisées pour apprendre.
- Testing data : données utilisées pour évaluer la généralisation.

5. Type d'apprentissage

Base de données (Dataset) :

- est un ensemble de données utilisé dans les tâches d'apprentissage automatique.
- Chaque élément de cet ensemble est appelé **un échantillon (sample)**.
- Les variables ou attributs qui décrivent les caractéristiques ou le comportement d'un échantillon sont appelés **caractéristiques (features)**.



29


Figure — Dataset : samples, features, labels (Chapitre_1_Introduction.pdf, p. 29)

PIPELINE

Cycle de vie projet ML

- Collecte → nettoyage/préparation → split train/test → choix modèle → entraînement → évaluation → amélioration → déploiement.
- Dans un devoir, toujours distinguer apprentissage sur train data et évaluation sur test data.

8. Cycle de vie d'un projet ML (ML Pipeline)



54

Figure — Cycle de vie ML (Chapitre_1_Introduction.pdf, p. 54)

2. Chapitre 2 — Régression & Régression linéaire

QCM

Régression : définition

- La régression prédit une valeur numérique continue : prix, température, durée, score.
- Différence TD : classification = catégories/classes ; régression = valeurs numériques continues.

Formules de régression

$$\text{Erreur individuelle : } e_i = y_i - \hat{y}_i$$

$$\text{MSE} = (1/n) \sum_i (y_i - \hat{y}_i)^2$$

$$\text{RMSE} = \sqrt{[(1/n) \sum_i (y_i - \hat{y}_i)^2]}$$

$$\text{MAE} = (1/n) \sum_i |y_i - \hat{y}_i|$$

$$\text{MAPE} = (100/n) \sum_i |(y_i - \hat{y}_i) / y_i|$$

$$\text{EV} = 1 - \text{Var}(y - \hat{y}) / \text{Var}(y)$$

INTERPRÉTER

Interprétation des métriques régression

- MSE/RMSE pénalisent les grandes erreurs.
- RMSE a la même unité que la variable cible.
- MAE est facile à interpréter et robuste.
- MAPE donne une erreur en %, mais attention si $y_i \approx 0$.
- EV proche de 1 signifie que le modèle explique mieux la variance.

Régression linéaire

II. La régression linéaire




Figure — But de la régression linéaire (Chapitre_II_RegressionLineaire.pdf, p. 11)

II. La régression linéaire

II.3 La régression linéaire




Figure — Hypothèse $H(x)=aX+b$ (Chapitre_II_RegressionLineaire.pdf, p. 12)

Régression linéaire simple et multiple

Simple : $H(x) = \hat{y} = aX + b$

Multiple : $\hat{y} = \beta_0 + \beta_1X_1 + \beta_2X_2 + \dots + \beta_pX_p$

Objectif : trouver les paramètres qui minimisent la fonction coût

Régression simple

- Une seule variable explicative X .
- Exemple : prix maison selon taille.

Régression multiple

- Plusieurs variables explicatives.
- Exemple : prix selon taille + chambres + adresse.

OPTIM

Fonction coût & optimisation

- La fonction coût mesure l'écart global entre les prédictions et les vraies valeurs.
- Coût faible : modèle proche des valeurs réelles.
- Deux approches du cours : Design Matrix Approach et Gradient Descent.

Design Matrix Approach

- Méthode matricielle/analytique.
- Adaptée aux petits nombres de features.
- Complexité élevée avec grandes matrices.

Gradient Descent

- Méthode itérative.
- Efficace sur grands datasets.
- Met à jour les paramètres pour réduire le coût.

II. La régression linéaire

II.3 La régression linéaire

Gradient Descent(G.D)

$$C(X) = [H(X) - Y]^2 = \sum_{i=1}^N \epsilon_i^2$$

$$H(X) = a * X + b$$

$$\begin{aligned} \frac{\partial C}{\partial b} &\longrightarrow b^+ = b - \alpha \frac{\partial C}{\partial b} \\ \frac{\partial C}{\partial a} &\longrightarrow a^+ = a - \alpha \frac{\partial C}{\partial a} \end{aligned}$$

α : Learning rate: taux d'apprentissage

Mme. Khaoula Tbarki

Figure — Gradient Descent (Chapitre_II_RegressionLineaire.pdf, p. 18)

PIÈGE


Learning rate — piège fréquent

- Learning rate trop petit : convergence lente mais plus stable.
- Learning rate trop grand : risque d'oscillation ou divergence.
- Rôle : taille du pas de mise à jour dans Gradient Descent.

II. La régression linéaire

II.3 La régression linéaire

α : Learning rate: taux d'apprentissage



Mme. Khaoula Tbarki

Figure — Learning rate (Chapitre_II_RegressionLineaire.pdf, p. 19)

3. Chapitre 3 — Régression non linéaire

IDÉE

Pourquoi passer au non linéaire ?

- La régression linéaire suppose une relation linéaire X-Y.
- Elle modélise mal les interactions complexes et relations non monotones.
- Une relation non linéaire peut être représentée par une courbe, un graphe ou un arbre.

Introduction



Mme. Khaoula Tbarki

Figure — Relation non linéaire (Chapitre3_RegressionNonLineaire.pdf, p. 7)

Decision Tree


IMPORTANT

Arbre de décision

- Modèle de classification ou régression construit en arborescence.
- Principe : partitionner l'espace d'entrée en régions selon des règles $\text{variable} \leq \text{seuil}$.
- Simple à interpréter, fonctionne avec variables continues et catégoriques.
- Risque : instabilité et overfitting si profondeur trop grande.

L'arbre de décision (Decision Tree)

Structure d'un Arbre



Mme. Khaoula Tbarki

Figure — Structure arbre de décision (Chapitre3_RegressionNonLineaire.pdf, p. 12)

Élément	Rôle
Root node	Nœud racine : première décision/split
Decision node	Nœud interne : test sur une feature

Leaf node	Feuille : prédiction finale
Critère régression	Réduction variance / MSE
Critère classification	Gini ou Entropie / Information Gain

Ensembling : Bagging, Random Forest, Boosting

CONCEPT

Ensembling

- Combiner plusieurs prédicteurs pour obtenir une prédiction finale meilleure qu'un seul modèle.
- Deux familles importantes : Bagging et Boosting.

Bagging

- Modèles indépendants entraînés en parallèle.
- Réduit la variance.
- Exemple : Random Forest.

Boosting

- Modèles séquentiels.
- Chaque nouveau modèle corrige les erreurs précédentes.
- Peut overfitter si mal réglé.

BAGGING

Random Forest

- Ensemble de nombreux arbres de décision.
- Utilisé en classification et régression.
- Avantages : réduit overfitting, moins de variance qu'un seul arbre, moins sensible au bruit.
- Inconvénient : plus coûteux qu'un arbre simple.

Bagging : Forêt Aléatoire (Random Forest)

- La forêt aléatoire est un classifieur composé de nombreux arbres de décision binaire.
- Plutôt que de simplement faire la moyenne de la prédiction des arbres.
- Utilisé dans la classification et la régression.




Figure — Random Forest (Chapitre3_RegressionNonLineaire.pdf, p. 32)

BOOSTING

Gradient Boosting & XGBoost


- Gradient Boosting : addition séquentielle de modèles faibles pour corriger les erreurs.
- XGBoost : version efficace et régularisée du boosting, souvent performante.
- À retenir : Random Forest = arbres indépendants ; Boosting = arbres séquentiels.

Boosting : Gradient Boosting

- Utilisé dans la classification et la régression.
- Ensemble de modèles de prédiction faibles : associent les décisions de plusieurs modèles pour améliorer les performances globales.
- À tout instant t , les résultats du modèle sont pondérés en fonction des résultats de l'instant précédent $t-1$.

+ Nouvel arbre corrige les erreurs commises par les arbres précédemment formés.

- Overfitting problem.



Mme. Khaoula Tbarki

Figure — Gradient Boosting (Chapitre3_RegressionNonLineaire.pdf, p. 35)

Paramétrique vs non paramétrique

Modèles paramétriques et non paramétriques

Modèles paramétriques

Un modèle où nous supposons la «forme» des données
Nous ne pouvons pas estimer les coefficients du modèle.
Exemple : Gaussian, Parzen, LDA, NDA,...

Modèles non paramétriques

Un modèle dans lequel nous ne supposons pas la «forme» des données
Nous devons estimer la forme la plus appropriée du modèle, ainsi que les coefficients (les paramètres).
Exemple : K-nearest neighbour, SVM, ...

Mme. Khaoula Tbarki

Figure — Paramétrique vs non paramétrique (Chapitre3_RegressionNonLineaire.pdf, p. 38)

Paramétrique

- Suppose une forme du modèle.
- Nombre fixe de paramètres.
- Exemples : régression linéaire, LDA.

Non paramétrique

- Ne suppose pas fortement une forme fixe.
- Complexité dépend davantage des données.
- Exemples : KNN, Decision Tree, SVM selon contexte.

4. Classification — métriques ajoutées demandées

TRÈS IMPORTANT

Pourquoi ces métriques ?

- Le TD montre que l'accuracy seule peut être trompeuse : un modèle peut avoir 98% accuracy mais seulement 15% recall pour les fraudes.
- Pour les classes déséquilibrées, il faut regarder Recall, Precision, F1-score, AUC et la matrice de confusion.

Matrice de confusion binaire

	Predit Positif	Predit Négatif
Réel Positif	TP : vrai positif	FN : faux négatif
Réel Négatif	FP : faux positif	TN : vrai négatif

Formules classification binaire

$$\text{Accuracy} = (TP + TN) / (TP + TN + FP + FN)$$

$$\text{Precision} = TP / (TP + FP)$$

$$\text{Recall} = \text{Sensitivity} = \text{TPR} = TP / (TP + FN)$$

$$\text{Specificity} = \text{TNR} = TN / (TN + FP)$$

$$\text{FPR} = FP / (FP + TN) = 1 - \text{Specificity}$$

$$\text{FNR} = FN / (FN + TP) = 1 - \text{Recall}$$

$$\text{F1-score} = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

$$\text{Balanced Accuracy} = (\text{Recall} + \text{Specificity}) / 2$$

COMMENTAIRE

Interprétation rapide

- Accuracy : proportion globale de bonnes prédictions.
- Precision : parmi les prédictions positives, combien sont correctes.
- Recall : parmi les vrais positifs, combien sont détectés.
- F1-score : compromis entre precision et recall.
- Specificity : capacité à détecter les négatifs.
- Balanced Accuracy : utile si les classes sont déséquilibrées.

ROC & AUC

ROC / AUC

ROC curve : courbe de TPR = Recall en fonction de FPR pour plusieurs seuils.

AUC = aire sous la courbe ROC.

Formule continue : $AUC = \int_0^1 TPR(FPR) d(FPR)$

Approximation trapèzes : $AUC \approx \sum_i [(TPR_i + TPR_{i-1})/2] \times (FPR_i - FPR_{i-1})$

TD

Interprétation AUC

- $AUC = 0.5$: modèle proche du hasard.
- AUC proche de 1 : excellente capacité à séparer les classes.
- Dans le TD : si Accuracy A = 92%, $AUC = 0.71$ et Accuracy B = 88%, $AUC = 0.91$, on préfère souvent B car il discrimine mieux sur plusieurs seuils.

5. Multiclasse — matrice du TD

EXERCICE

Matrice de confusion 3 classes du TD

- Matrice donnée : $[[50,0,0],[0,47,3],[0,2,48]]$.
- La diagonale contient les bonnes prédictions : 50, 47, 48.
- La valeur 3 signifie : classe réelle C2 prédite comme C3 si les lignes sont les classes réelles.
- La valeur 2 signifie : classe réelle C3 prédite comme C2 si les lignes sont les classes réelles.

Classe	TP	FN	FP	Recall	Precision
C1	50	0	0	$50/(50+0)=1.00$	$50/(50+0)=1.00$
C2	47	3	2	$47/(47+3)=0.94$	$47/(47+2)=0.959$
C3	48	2	3	$48/(48+2)=0.96$	$48/(48+3)=0.941$

Accuracy multiclasse TD

$$\text{Accuracy} = \text{somme diagonale} / \text{somme totale} = (50 + 47 + 48) / 150 = 145/150 = 0.9667 = 96.67\%$$

RÉPONSE

Interprétation

- Le modèle est très bon globalement : 145 bonnes prédictions sur 150.
- La classe C1 est parfaitement reconnue.
- Les erreurs principales sont entre C2 et C3 : 3 erreurs C2→C3 et 2 erreurs C3→C2.

6. Partie inspirée TD — QCM, réponses et pièges

TD n°1

Exercice 1 : QCM

Répondre aux questions suivantes en donnant LA bonne réponse.

- Quelle est la différence entre une tâche de classification et de régression ?
 - La classification prédit des catégories, tandis que la régression prédit des valeurs numériques continues.
 - La régression est plus rapide à entraîner que la classification.
 - La classification utilise exclusivement des algorithmes supervisés.
 - Il n'y a pas de réelle différence entre classification et régression.
- Un arbre de décision peut être utilisé en :
 - Régression seulement
 - Classification seulement
 - Classification et régression
 - Classification et régression
- Dans un arbre de décision, que signifie une profondeur (depth) trop importante ?
 - L'arbre est plus susceptible de surapprendre les données d'entraînement.
 - L'arbre est moins généralisable aux données de test.
 - L'arbre peut fonctionner avec des données non équilibrées.
 - L'arbre ne peut pas être utilisé pour des tâches de classification.
- Quel type d'apprentissage est utilisé pour regrouper automatiquement des données similaires ?
 - Apprentissage supervisé
 - Apprentissage par renforcement
 - Apprentissage non supervisé
 - Deep Learning uniquement
- Dans l'apprentissage par renforcement, l'agent apprend grâce :
 - Aux étiquettes des données
 - Aux récompenses et pénalités
 - Aux bases de données relationnelles
 - Aux équations différentielles
- Un modèle de détection de fraude bancaire donne : Accuracy = 98% - Rappel (recall) = 15%. Quelle est votre conclusion ?
 - Le modèle est excellent, 98% d'accuracy est très satisfaisant
 - Il faut augmenter le seuil de décision pour améliorer l'accuracy
 - Le modèle est inutilisable, il ne détecte que 15% des fraudes réelles
 - Le dataset est trop petit, collecter plus de données
- Un étudiant entraîne KNN sur un dataset avec deux features : Salaire (entre 1000 et 10000) et Nombre d'enfants (entre 0 et 5). Il utilise de normaliser. Quel est l'effet ?
 - KNN ne peut pas s'entraîner sans normalisation, une erreur est levée
 - Aucun effet, KNN est insensible aux échelles

Figure — QCM TD — exemples de questions (TD_n1.pdf, p. 1)

QCM probables corrigés

Question type	Bonne réponse	Pourquoi
Classification vs régression	Classification = catégories ; régression = valeurs continues	Question directe du TD.
Decision Tree utilisé en	Classification et régression	Un arbre peut prédire une classe ou une valeur continue.
Depth trop grande	Overfitting	L'arbre mémorise trop les données train.
Regrouper données similaires	Apprentissage non supervisé	Clustering sans labels.
Renforcement	Récompenses et pénalités	Agent apprend par interaction.
Fraude : accuracy 98%, recall 15%	Modèle mauvais pour détecter fraudes	Il rate 85% des fraudes réelles.
KNN sans normalisation	Feature à grande échelle domine	Salaire domine nombre d'enfants.
AUC 0.91 vs accuracy plus élevée	Choisir AUC si discrimination importante	AUC évalue plusieurs seuils.

Questions de cours style TD

EXAMEN

Réponses courtes à mémoriser

- Random Forest vs Decision Tree : Random Forest combine plusieurs arbres, réduit variance et overfitting ; Decision Tree est un seul arbre plus simple mais instable.
- Critère Gini/Entropie : mesure l'impureté pour choisir le meilleur split.
- Régression simple vs multiple : simple = une feature ; multiple = plusieurs features.
- Éviter overfitting : réduire profondeur, pruning, régularisation, cross-validation, plus de données, data augmentation, early stopping.
- Supervisé vs non supervisé : supervisé avec labels ; non supervisé sans labels pour découvrir des groupes.

- c. Le modèle overfite systématiquement
 d. Le modèle classe uniquement sur le Salaire, Nombre d'enfants s'a quasi aucune
8. Vous comparez deux modèles sur un dataset de détection de maladie : Modèle A : Accuracy = 92%, AUC = 0.71, Modèle B : Accuracy = 88%, AUC = 0.91. Lequel choisissez-vous et pourquoi ?
- a. Modèle A : son accuracy est plus élevée : c'est la métrique principale
 b. Modèle B : AUC est plus élevée : il discrimine mieux les deux classes sur tous les seuils possibles
 c. Les deux sont équivalents : accuracy et AUC mesurent la même chose
 d. Modèle A : une AUC de 0.91 indique un overfitting du modèle B

Exercice 2 : Question de cours

Répondez brièvement (1 à 2 phrases maximum).

- Expliquez différences entre Random Forest et decision tree.
- Dans un arbre de décision, donner le rôle du critère d'impureté (par exemple, entropie ou Gini) ?
- Citez différences entre la régression linéaire simple et la régression linéaire multiple ?
- Comment éviter le problème de surapprentissage en Machine Learning ?
- Expliquez la différence entre les approches supervisées et non supervisées, avec un exemple pour chaque.

Exercice 3

- Après l'apprentissage sur un ensemble des données, le modèle donne 0.97 en termes de Recall sur les données de test.

Que peut-on conclure

- Soit la matrice de confusion suivante de trois classes C1, C2 et C3 :

50	0	0
0	47	3
0	2	48

- Que représente la diagonale ?
- Que représente la valeur 50 de la matrice de confusion ?
- Que représente la valeur 2 de la matrice de confusion ?
- Calculer Recall pour chaque classe.
- Calculer la précision de chaque classe.
- Calculer l'accuracy.
- Interpréter résultat de la matrice de confusion.

Exercice N°4 (3 pts)

- Donnez les différences entre de Knn et Decision Tree.

Figure — Questions de cours + matrice de confusion (TD_n1.pdf, p. 2)

7. Overfitting, Underfitting, Best fitting

CONCEPT


Définitions

- Underfitting : modèle trop simple, mauvaise performance sur train et test, biais élevé.
- Overfitting : modèle trop complexe, très bon sur train mais mauvais sur test, variance élevée.
- Best fitting : bon compromis biais/variance, bonnes performances sur train et test.

Phénomène	Train	Test	Cause	Solution
Underfitting	Erreur élevée	Erreur élevée	Modèle trop simple	Modèle plus complexe, meilleures features
Overfitting	Erreur faible	Erreur élevée	Modèle mémorise train	Régularisation, pruning, validation, moins de profondeur
Best fitting	Erreur faible/modérée	Erreur faible	Bon compromis	Garder configuration

2) Les figures suivantes représentent les résultats d'une classification lors de l'étape d'apprentissage. Lesquelles de ces figures illustrent respectivement l'overfitting, l'underfitting et le meilleur ajustement (best fitting) et justifier votre réponse?

3) Expliquer en détail chaque phénomène.



Exercice 5 : Étude de cas

Figure — Overfitting / underfitting / best fitting (TD_n1.pdf, p. 3)

8. Checklist finale avant devoir

- ☐ Je sais expliquer IA, ML, Deep Learning.
- ☐ Je sais différencier supervisé, non supervisé, semi-supervisé et renforcement.
- ☐ Je sais expliquer sample, feature, label, train/test.
- ☐ Je sais choisir entre classification et régression.
- ☐ Je connais $H(x)=aX+b$ et la régression multiple.
- ☐ Je sais interpréter MSE, RMSE, MAE, MAPE, EV.
- ☐ Je sais expliquer Decision Tree, Random Forest, Bagging, Boosting, XGBoost.
- ☐ Je sais calculer Accuracy, Precision, Recall, F1-score.
- ☐ Je sais lire une matrice de confusion.
- ☐ Je comprends AUC/ROC et pourquoi accuracy seule peut tromper.
- ☐ Je sais expliquer overfitting/underfitting/best fitting.

PLAN

Méthode 30 minutes

- 10 min : lire les encadrés bleus/verts.
- 10 min : refaire les formules classification + régression.
- 5 min : refaire la matrice TD.
- 5 min : répondre oralement aux QCM probables.